Trabajo Práctico

Teoría de Lenguajes

Segundo cuatrimestre 2015

1 Introducción

El objetivo de este trabajo práctico es desarrollar un compositor de fórmulas matemáticas. El mismo tomará como entrada la descripción de una fórmula en una versión muy simplificada del lenguaje utilizado por LaTeX y producirá como salida un archivo SVG (Scalable Vector Graphics).

Para simplificar el trabajo utilizaremos una tipografía monoespaciada. Esto permitirá resolver el problema sin necesidad de contar con información sobre la métrica de los distintos caracteres de la tipografía.

2 Lenguaje de entrada

La siguiente gramática ambigua describe la sintaxis que deben seguir las expresiones que acepte el programa:

E	$\rightarrow$	$E\ E$	(concatenación)
	$\mid$	E `^` E	(superíndice)
	$\mid$	E `_` E	(subíndice)
	$\mid$	E `^` E `_` E	(super y subíndice)
	$\mid$	E `_` E `^` E	(sub y superíndice)
	$\mid$	E `/` E	(división)
	$\mid$	`(` E `)`	(encerrar entre paréntesis)
	$\mid$	`{` E `}`	(agrupar)
	$\mid$	l	(cualquier caracter salvo `^`, `_`, `/`, {, }, `(` y `)`)

Para eliminar la ambigüedad en la interpretación, se debe tener en cuenta que la división es la de menor precedencia, seguida de la concatenación. Ambas son asociativas a izquierda. El superíndice y subíndice son no asociativos (no es lícito escribir `a^b^c` ni `a_b_c`) y tienen más precedencia que la concatenación. Por ejemplo, la cadena `(A^BC^D/E^F_G+H)-I` es equivalente a `{({{A^B}{C^D}}/{{{E^F_G}+}H})-}I`, y el resultado se podría ver así:

$$\left(\frac{\mathtt{A}^{\mathtt{B}}\mathtt{C}^{\mathtt{D}}}{\mathtt{E}_{\mathtt{G}}^{\mathtt{F}}\mathtt{+H}}\right)\mathtt{-I}$$

3 Descripción de la salida

Scalable Vector Graphics (SVG) es un formato estándar de imágenes vectoriales[1] basado en XML[2] creado por el W3C[3]. Describiremos algunas caracteristicas del formato SVG, pero se pueden encontrar más detalles en la documentación oficial[4].

En SVG un elemento `text` escribirá un texto en las posiciones establecidas por las coordenadas x e y. La coordenada y indica la línea de base para el texto. Una vez que se presenta el primer caracter en la posición especificada, se actualiza la *posición actual* sumándole el valor de *avance* del caracter escrito para escribir a continuación el caracter siguiente.

En el sistema de coordenadas de SVG, la posición $(x, y) = (0, 0)$ es la correspondiente al extremo superior izquierdo.

Existen distintas convenciones para especificar tamaños de letra. Una de las más usadas es la de indicar el interlineado para el cual está diseñada la tipografía. Cuando se habla de una tipografía de 10 unidades usando esta convención, se quiere decir que la tipografía está diseñada para que la distancia vertical entre las líneas de base de los caracteres sea de 10 unidades cuando se usa interlineado normal. En la tipografía monoespaciada Courier, la separación horizontal entre cada caracter (el *avance*) es el mismo para todos: el 60 % del interlineado. En SVG el tamaño del texto se establece mediante el atributo *font-size*.

Por ejemplo, los elementos:

```
<text x="10" y="50" font-family="Courier" font-size="10">
The quick brown fox
</text>
<text x="10" y="60" font-family="Courier" font-size="10">
jumps over the lazy dog
</text>
```

producen el siguiente resultado:

The quick brown fox
jumps over the lazy dog

al que le agregamos una grilla y algunas anotaciones para que se vea cuáles son las dimensiones y coordenadas resultantes:

[1] Las imágenes vectoriales pueden ser reducidas o agrandadas a cualquier tamaño sin perder datos ni pixelarse.

[2] http://www.w3.org/XML/

[3] World Wide Web Consortium

[4] http://www.w3.org/TR/SVG/

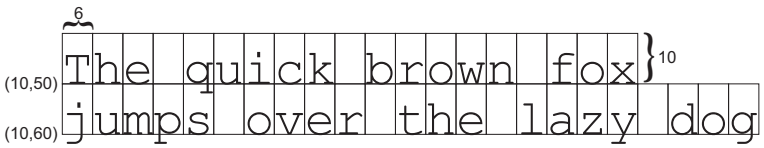

Para el super y subíndice se suele reducir el tamaño de letra a un 70 % del original y desplazar la línea de base hacia arriba o hacia abajo respectivamente. Para las divisiones, la línea de división se suele alinear con la línea horizontal de los signos más y menos (aproximadamente 28 % del interlineado sobre la línea de base). El numerador y el divisor se ubican centrados horizontalmente con respecto a la línea de división.

En el cuadro 1 se ve una posible salida para la cadena de entrada `(A^BC^D/E^F_G+H)-I`, cuya imagen mostramos en la sección anterior. En este ejemplo se utiliza un elemento `text` para cada caracter de salida especificando su posición y tamaño.

Cuadro 1: Ejemplo de salida para la cadena de entrada `(A^BC^D/E^F_G+H)-I`

```
<?xml version="1.0" standalone="no"?>
<!DOCTYPE svg PUBLIC "-//W3C//DTD SVG 1.1//EN"
  "http://www.w3.org/Graphics/SVG/1.1/DTD/svg11.dtd">
<svg xmlns="http://www.w3.org/2000/svg" version="1.1">
<g transform="translate(0, 200) scale(200)" font-family=
"Courier">
    <text x="0" y="0" font-size="1" transform=
    "translate(0, 1.36875) scale(1,2.475)">(</text>
    <text x=".69" y=".53" font-size="1">A</text>
    <text x="1.29" y=".08" font-size=".7">B</text>
    <text x="1.71" y=".53" font-size="1">C</text>
    <text x="2.31" y=".08" font-size=".7">D</text>
    <text x="0.6" y="1.68" font-size="1">E</text>
    <text x="1.2" y="1.93" font-size=".7">G</text>
    <text x="1.2" y="1.23" font-size=".7">F</text>
    <text x="1.62" y="1.68" font-size="1">+</text>
    <text x="2.22" y="1.68" font-size="1">H</text>
    <text x="0" y="0" font-size="1" transform=
    "translate(2.82, 1.36875) scale(1,2.475)">)</text>
    <text x="3.42" y="1" font-size="1">-</text>
    <text x="4.02" y="1" font-size="1">I</text>
</g>
</svg>
```

Para que los paréntesis de agrupamiento abarquen verticalmente la subexpresión que encierran utilizamos una transformación. El atributo *transform* representa una secuencia de transformaciones del sistema de coordenadas

para el elemento al que se le aplica y toda su descendencia. *translate* le suma a las coordenadas los valores indicados. *scale* multiplica las coordenadas por los valores indicados. Si hay un sólo parámetro, entonces multiplica ambas coordenadas por dicho valor. Las transformaciones se aplican de derecha a izquierda (en el ejemplo del cuadro 1, primero el *scale* luego el *translate*). En dicho ejemplo, el símbolo (está en las posiciones x=0, y=473.75. Esto resulta de multiplicar las coordenadas del elemento por el scale (1, 2.475), sumarle el translate (0, 1.36875) y luego multiplicar por el scale(200) para finalmente sumarle el translate (0, 200). El scale también afecta al tamaño de letra, resultando en con tamaño (200, 495). El mayor valor sobre el eje y indica que el caracter se verá estirado verticalmente.

4 Modo de uso

El programa debe poder ser invocado por línea de comandos, recibiendo como parámetro la especificación de la fórmula y escribiendo el resultado en su salida standard o en un archivo. En caso de que lo recibido como parámetro no sea una fórmula válida se lo debe informar en la salida de error standard.

Alternativamente, si usan una herramienta que genere código JavaScript el programa puede residir en una página web que muestre el resultado en forma interactiva.

5 Implementación

Hay dos grupos de herramientas que se pueden usar para generar los analizadores léxicos y sintácticos, y agregar las acciones requeridas para generar el documento de salida:

- Uno utiliza expresiones regulares y autómatas finitos para el análisis lexicografico, y la técnica LALR para el análisis sintáctico. Ejemplos de esto son lex y yacc, que generan código C o C++, JLex y CUP, que generan código Java y ply, que genera código Python. flex y bison son implementaciones libres y gratuitas de lex y yacc. Son parte de todas las distribuciones Linux. Para Windows pueden ser instalados como parte de Cygwin, (http://www.cygwin.com/) o de DJGPP (http://www.delorie.com/djgpp/). También se pueden conseguir en forma independiente en http://www.gnu.org/. JLex y CUP se pueden conseguir en http://www.jflex.de/ y http://www2.cs.tum.edu/projects/cup/ y ply en https://pypi.python.org/pypi/ply.

- El otro grupo utiliza la técnica ELL(k) tanto para el análisis léxico como para el sintáctico, generando parsers descendentes iterativos recursivos. Ejemplos son JavaCC, y ANTLR, que están escritos en

Java. JavaCC puede generar código Java o C++. ANTLR puede generar Java, C#, Python y JavaScript. ANTLR se puede conseguir en http://www.antlr.org/ y JavaCC en https://javacc.java.net/.

Si quieren usar otra herramienta, consúltenlo con alguno de los docentes.

6 Detalles de la entrega

Se deberá enviar el código a la dirección de e-mail tptleng@gmail.com.

La entrega debe incluir:

- Un programa que cumpla con lo solicitado
- El código fuente del programa.
- Informe conteniendo:
  - el código de la solucion. Si se usaron herramientas generadoras de código, imprimir la fuente ingresada a la herramienta, no el código generado.
  - Las modificaciones a la gramática o indicaciones adicionales que hayan sido necesarias para construir el parser.
  - Descripción de cómo se implementó la solución.
  - Información y requerimientos de software para ejecutar y recompilar el tp (versiones de compiladores, herramientas, plataforma, etc). Sería como un pequeño manual del usuario, que además de los requerimientos, contenga instrucciones para correrlo, información de parámetros y lo que consideren necesarios.
  - Casos de prueba con expresiones sintácticamente correctas e incorrectas, resultados obtenidos y conclusiones.